

MoonRobots Gate

原创 MoonBit 开源库与开发工具 | robots.txt 可解释策略审计与抓取规划

参赛者	石子硕	报名邮箱	2111950632@qq.com
联系电话	18713029718	公开仓库	https://github.com/2111950632/moonrobots-gate
Mooncakes	2111950632/robots-gate	许可证	Apache-2.0
核心库 4,284 行		MoonBit 总计 5,745 行	102 项测试通过
			12 个核心模块

项目简介

MoonRobots Gate 将 robots.txt 文本转换为可检查的数据模型，为爬虫、搜索引擎、链接检查器、文档工具和 AI 智能体提供确定的访问判断、风险诊断、站点地图校验与抓取规划能力。

一、项目现有基础

项目已有可运行的 MoonBit 0.2.0 本地原型，完成防御式策略解析、用户代理选择、最长规则匹配、Allow 同长优先、通配符与末尾锚点、百分号编码归一化、决策轨迹、语义检查、策略渲染、访问矩阵、策略差异、站点地图校验和预算抓取规划。现有九组 CLI 命令、四个示例和 102 项测试；格式检查、类型检查、构建、测试和发布包检查均已通过。

二、本次计划开发或新增的内容

1. 增加独立网络获取层，处理重定向、HTTP 状态、正文大小限制、缓存时间和失败回退。2. 增加多站点批量审计及 Markdown、JSON、CSV 报告。3. 扩充 RFC 9309 兼容性夹具、畸形输入、编码边界和资源上限测试。4. 完善 CLI 配置、错误处理、报告导出和真实工作流示例。5. 整理公共 API、兼容性、维护和发布文档，并完成公开仓库及 Mooncakes 发布。

三、预期目标与技术路线

采用“纯策略核心 + 可替换传输层”的分层结构：文本先经过限额解析和源位置诊断，再进入用户代理选择与路径匹配；上层复用统一决策结果完成语义审计、版本差异、站点地图检查和抓取规划；传输层只负责网络状态、缓存和内容获取。目标是形成可公开复用、可在 CI 中稳定运行的工具包，预计达到约 7,000 至 9,000 行有效 MoonBit 代码。功能边界不包含页面解析、JavaScript 渲染和完整网络爬虫。

四、预计完成的功能、测试与文档

功能包括网络获取与缓存、批量审计、结构化报告、完整 CLI、站点地图策略检查和预算抓取规划。测试目标不少于 150 项，覆盖协议语义、异常输入、网络状态、缓存、批量任务和回归夹具。提供策略判断、批量审计、站点地图、抓取规划和 CI 示例。文档包括 README、API 说明、架构设计、协议兼容性、维护指南、更新日志和发布记录。CI 持续验证格式、类型、构建、测试和发布包。

五、原创性与许可证说明

本项目为原创 MoonBit 实现，不是其他开源库的直接移植，也未复制第三方项目源码。协议行为参考 RFC 9309、RFC 3986 和公开的 Robots 解析文档，仅用于理解公开标准。项目采用 OSI 认可的 Apache-2.0 许可证，核心运行时依赖仅为 moonbitlang/core；新增依赖将在引入前核查许可证并记录来源。

报名及材料提交以本次 8 月黑客松飞书问卷和后续官方通知为准。